

Đề xuất Project Module 03

SHAP Stability under Correlated Time-Series Features

Nhóm 5 thành viên – AIO Conquer 2026, Module 03

Thời gian thực hiện: 2 tuần

1 Mục tiêu project

Project nghiên cứu độ ổn định của SHAP khi mô hình gradient boosting sử dụng các feature time-series mang thông tin tương quan. Bài toán dự báo nhu cầu gọi xe theo khu vực được dùng làm môi trường thực nghiệm; mục tiêu chính không phải xây dựng hệ thống forecasting phức tạp mà là đánh giá mối quan hệ giữa cách biểu diễn weekly lag, hiệu năng dự báo và độ ổn định của phân diễn giải.

Câu hỏi nghiên cứu chính:

Trong dữ liệu demand theo giờ của NYC, các weekly lag có mức tương quan như thế nào; SHAP feature importance của chúng ổn định ra sao qua các fold theo thời gian; và việc gộp các feature này ảnh hưởng như thế nào đến explanation stability và forecasting performance so với cách giữ chúng riêng lẻ?

Project trả lời câu hỏi trên bằng hai nhóm bằng chứng:

- **Prediction:** so sánh MAE, RMSE và WAPE giữa các cách biểu diễn weekly lag.
- **Explanation:** so sánh mean và standard deviation của SHAP importance qua các temporal fold, ở cả mức feature riêng lẻ và mức weekly group.

2 Phạm vi và protocol cố định

2.1 Dữ liệu, target và feature

Dataset: NYC TLC High Volume For-Hire Vehicle (HVFHV) Trip Records, 12 tháng của năm 2025.

Đơn vị dữ liệu: một row tương ứng với một zone và một target hour t . Target là số request trong target hour đó. Mọi lag feature của row tại t chỉ được tính từ demand trước t .

Quy tắc xử lý dữ liệu:

- Chỉ đọc các cột cần thiết từ raw trip data, tối thiểu gồm `request_datetime` và `PULocationID`; aggregate từng tháng theo `zone × hour`, lưu bằng aggregate rồi giải phóng raw data.
- Chọn cố định 50 zone có tổng demand cao nhất trong giai đoạn 01/01–30/06/2025. Danh sách này được freeze trước khi dùng các tháng đánh giá.
- Với 50 zone đã chọn, dựng lưới hourly đầy đủ cho toàn năm và giữ giờ có demand bằng 0.
- Do cần `lag_504`, các row dùng cho model bắt đầu từ 22/01/2025 sau giai đoạn warm-up.

- PULocationID được one-hot encode bằng vocabulary cố định của 50 zone. Không scale feature vì hai model chính đều là tree-based model.

Feature nền giữ cố định giữa các variant:

- Feature thời gian: hour, dayofweek, is_holiday.
- is_holiday dùng lịch ngày nghỉ liên bang Hoa Kỳ; weekend đã được biểu diễn qua dayofweek.
- Lag ngắn hạn: lag_1 và lag_24.

Không đưa hour_of_week, weather, neighboring-zone demand, borough demand, dashboard hoặc deployment vào core scope. Việc bỏ hour_of_week giúp tránh thêm một feature lịch có quan hệ xác định với hour và dayofweek, qua đó giữ trọng tâm phân tích ở nhóm weekly lag.

2.2 Ba variant và baseline

Ba variant dùng cùng dataset, target và feature nền; chỉ nhóm weekly lag thay đổi.

Variant	Weekly feature	Vai trò
A	lag_168, lag_336, lag_504 giữ riêng	Baseline: giữ nguyên các weekly lag riêng lẻ
B	median_lag_3w median(lag_168, lag_336, lag_504)	= Aggregation: gộp ba weekly lag thành một đại diện
C	lag_168 + median_lag_3w	Hybrid: giữ tuần gần nhất riêng và thêm đại diện gộp

Trước core experiment, correlation giữa ba weekly lag được đo bằng Pearson correlation theo từng zone trên giai đoạn 22/01–31/07/2025. Với mỗi cặp lag, báo cáo mean và standard deviation của hệ số correlation trên 50 zone. Không đặt trước một ngưỡng bắt buộc để gọi kết quả là “cao”; giá trị quan sát được sẽ quyết định mức độ mạnh của kết luận.

2.3 Split theo thời gian

Toàn bộ split được cố định theo target hour; không dùng random K-fold.

Giai đoạn	Train	Validation/Test
HPO	22/01–30/06	01/07–31/07
Fold 1	22/01–31/07	01/08–31/08
Fold 2	22/01–31/08	01/09–30/09
Fold 3	22/01–30/09	01/10–31/10
Fold 4	22/01–31/10	01/11–30/11
Final test	22/01–30/11	01/12–31/12

Không cần gap riêng vì row tại target hour t chỉ sử dụng feature từ $t - 1$ trở về trước. QA/QC phải xác minh lag alignment bằng sample cụ thể trước khi chạy toàn bộ experiment.

2.4 Model, baseline config và Optuna

Hai model được dùng để kiểm tra tính nhất quán của phát hiện, không phải để biến project thành bài model comparison:

- LightGBM Regressor.
- XGBoost Regressor.

Random seed chung: 42 cho model, Optuna và mọi bước sampling.

Baseline config trước tuning:

Model	Baseline config
LightGBM	objective=regression, n_estimators=300, learning_rate=0.05, num_leaves=31, min_child_samples=20, colsample_bytree=1.0, random_state=42, n_jobs=-1
XGBoost	objective=reg:squarederror, tree_method=hist, n_estimators=300, learning_rate=0.05, max_depth=6, min_child_weight=1, subsample=1.0, colsample_bytree=1.0, random_state=42, n_jobs=-1

Optuna protocol:

- Tuning đúng 20 trials cho mỗi model bằng `TPESampler(seed=42)`.
- Tuning chỉ dùng Variant A trên HPO split; objective là MAE của tháng 07/2025.
- Sau tuning, best config của từng model được freeze và dùng nguyên vẹn cho A/B/C ở Fold 1–4 và final test. Không tune lại theo variant hoặc fold.

Model	Search space
LightGBM	n_estimators $\in \{200, 300, 400, 500, 600\}$; learning_rate $\in [0.03, 0.10]$ log-scale; num_leaves $\in [15, 63]$; min_child_samples $\in [20, 100]$; colsample_bytree $\in [0.7, 1.0]$
XGBoost	n_estimators $\in \{200, 300, 400, 500, 600\}$; learning_rate $\in [0.03, 0.10]$ log-scale; max_depth $\in [4, 8]$; min_child_weight $\in [1, 10]$; subsample $\in [0.7, 1.0]$; colsample_bytree $\in [0.7, 1.0]$

Các tham số không nằm trong search space giữ nguyên như baseline config. Nhóm lưu kết quả baseline và tuned config trên HPO split để báo cáo tác động của tuning.

2.5 Prediction metric

Với n row đánh giá, dùng ba metric:

$$\text{MAE} = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|,$$

$$\text{RMSE} = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2},$$

$$\text{WAPE} = \frac{\sum_{i=1}^n |y_i - \hat{y}_i|}{\sum_{i=1}^n |y_i|} \times 100\%.$$

MAE là metric chính dùng cho model selection. RMSE và WAPE là metric bổ sung. Mỗi Fold 1–4 tính metric trên toàn bộ validation rows và báo cáo **mean $\pm$ standard deviation** qua 4 fold. Final test tháng 12 được báo cáo riêng, không gộp vào mean/std của CV.

2.6 SHAP protocol và stability metric

SHAP chỉ được tính sau khi model của một fold đã hoàn tất. Protocol cố định:

- Dùng `shap.TreeExplainer` với `feature_perturbation` đặt thành `tree_path_dependent` cho cả LightGBM và XGBoost.
- Trên mỗi validation fold, lấy 100 row ngẫu nhiên cho mỗi zone, tổng cộng 5,000 row, với seed 42. Cùng tập row được dùng cho A/B/C và cả hai model trong cùng fold.
- Với feature j ở fold f , global importance được định nghĩa:

$$I_{j,f} = \frac{1}{|S_f|} \sum_{i \in S_f} |\phi_{i,j,f}|.$$

- Qua 4 fold, báo cáo mean và sample standard deviation của $I_{j,f}$:

$$\bar{I}_j = \frac{1}{4} \sum_{f=1}^4 I_{j,f}, \quad s_j = \sqrt{\frac{1}{3} \sum_{f=1}^4 (I_{j,f} - \bar{I}_j)^2}.$$

Không dùng coefficient of variation hoặc significance test trong core scope. Standard deviation được diễn giải cùng mean importance; không kết luận một feature “ổn định hơn” chỉ dựa vào standard deviation nếu mức mean importance khác nhau quá lớn.

Để phân tích ở mức weekly group, với từng fold dùng:

- Variant A: $I_{\text{weekly},f} = I_{168,f} + I_{336,f} + I_{504,f}$.
- Variant B: $I_{\text{weekly},f} = I_{\text{median3w},f}$.
- Variant C: $I_{\text{weekly},f} = I_{168,f} + I_{\text{median3w},f}$.

Mỗi variant báo cáo mean $\pm$ standard deviation của weekly-group importance qua 4 fold. Đây là phân tích bổ sung cho feature-level result, không thay thế prediction metrics.

3 Đầu vào và đầu ra

3.1 Đầu vào

- NYC TLC HVFHV Trip Records 01–12/2025 và Taxi Zone Lookup.
- Protocol trong tài liệu này: target definition, 50-zone rule, feature set, Variant A/B/C, split dates, seed, model baseline, Optuna search space, prediction metrics và SHAP protocol.

3.2 Đầu ra bắt buộc

- Hourly panel và final feature table đủ để tạo A/B/C mà không tính lại raw trip data.
- Correlation summary của ba weekly lag theo zone.
- Baseline-vs-tuned result trên HPO split cho LightGBM và XGBoost.
- Kết quả A/B/C $\times$ LightGBM/XGBoost trên Fold 1–4: MAE, RMSE, WAPE theo từng fold và mean $\pm$ standard deviation.
- Final test tháng 12 cho cả 6 model-variant combinations.

- Per-fold SHAP importance, mean/std qua fold và weekly-group importance.
- Source code/config có thể chạy lại core pipeline và artifact có thể truy vết theo model/variant/fold.
- Báo cáo và slide. Related Work, literature review, Results/Discussion và limitations được hoàn thiện sau khi core experiment có kết quả thực tế.

4 Phân chia công việc

Vai trò	Trách nhiệm chính
Tech Lead	Giữ scope/RQ và protocol cố định; điều phối handoff; review experiment matrix, artifact và claim cuối; chỉ cho phép thay protocol khi có lỗi blocking được ghi nhận rõ.
AI Data	Tải/aggregate 12 tháng HVFHV; chọn top-50 zone theo Jan-Jun; dựng panel; tạo đúng feature; kiểm tra leakage; tính Pearson correlation theo zone và bàn giao feature table.
AI Pipeline	Cài đặt split cố định, config, runner, metric functions, SHAP sampling và artifact structure; bảo đảm mọi run dùng cùng row/split/config theo protocol.
AI Model	Chạy baseline, Optuna 20 trials/model, freeze best configs; chạy A/B/C trên Fold 1-4 và final test; tính prediction/SHAP metrics theo đúng định nghĩa.
QA/QC	Audit target/lag/split, recompute MAE/RMSE/WAPE và SHAP summary trên subset, kiểm tra frozen config và reproduce ít nhất một core run trước khi nộp.

5 Kế hoạch thực hiện trong 14 ngày

5.1 Ngày 1-3: dữ liệu và xác minh protocol

1. Aggregate raw HVFHV theo tháng, chọn top-50 zone theo Jan-Jun và dựng panel toàn năm.
2. Tạo feature table, A/B/C và correlation summary; QA/QC kiểm tra lag alignment và leakage.
3. Pipeline cài đặt chính xác HPO split, Fold 1-4, final test, metric functions, seed và artifact naming theo tài liệu này.

5.2 Ngày 4-9: model và core experiment

1. Ngày 4: chạy baseline và Optuna 20 trials cho LightGBM trên HPO split; freeze config.
2. Ngày 5: chạy baseline và Optuna 20 trials cho XGBoost trên HPO split; freeze config.
3. Ngày 6-8: chạy đầy đủ A/B/C trên Fold 1-4 cho cả hai model; lưu prediction và SHAP sample/artifact.
4. Ngày 9: chạy final test tháng 12 cho cả 6 combinations và rerun các core run lỗi nếu có.

5.3 Ngày 10–14: tổng hợp, QA và báo cáo

1. Ngày 10–11: tổng hợp MAE/RMSE/WAPE, mean/std của SHAP importance và weekly-group result; trả lời trực tiếp research question bằng bảng/bảng/hình.
2. Ngày 12: viết phần Data, Method và Experimental Setup từ protocol đã chạy thực tế; bắt đầu Results dựa trên artifact đã xác minh.
3. Ngày 13: QA/QC reproduce subset, audit số liệu và claim; sửa các lỗi blocking.
4. Ngày 14: hoàn thiện report/slide. Related Work, literature review, Discussion và limitations chỉ được viết dựa trên kết quả và phạm vi thực tế, không mở thêm experiment ngoài core matrix.

6 Tiêu chí hoàn thành

Project được xem là hoàn thành khi nhóm có thể trả lời bằng kết quả thực nghiệm và artifact truy vết được:

1. Mức tương quan thực tế giữa `lag_168`, `lag_336`, `lag_504` là bao nhiêu và có đồng nhất giữa các zone hay không?
2. Với protocol cố định, mean và standard deviation của SHAP importance qua temporal folds cho các weekly feature thay đổi như thế nào ở Variant A/B/C?
3. Các cách gộp feature ở B/C ảnh hưởng như thế nào đến MAE, RMSE, WAPE và weekly-group SHAP stability so với baseline A, và xu hướng có nhất quán giữa LightGBM và XGBoost hay không?

Không cần thêm model, dataset, statistical test, deployment hoặc experiment ngoài phạm vi trên để coi core project là hoàn thành.